

Guião Estágio (Fase Final)

Rafael André

Índice

1	Lista (Reunião 30/04)	3
1.1	Fine-Tune da ResNet	3
1.2	Agregação de Resultados	3
1.2.1	Tipo 1	3
1.2.2	Tipo 2	3
1.3	Classificação 2.5D	4
1.4	Identificação de tipo de fibrose	4
1.5	CT-FM	4
1.5.1	Questão	5
1.6	Desenvolvimento do Report	5
1.6.1	Introdução	5
1.6.2	Estado da Arte	5
1.6.3	Descrição da Base de Dados	5
1.6.4	Metodologia	5

1 Lista (Reunião 30/04)

Representa a ordem pela qual penso fazer o sugerido.

No dia 05/05:

- Falta receber confirmação de qual método devo usar em “modelo com a melhor loss validation”
- Falta teste de “resize before augmentations”
- Falta implementar ideia de agregação de resultados, bem como escolha de critérios
- Decidi deixar agregação de resultados por features da última camada convolucional para o final (bastante complexo)

1.1 Fine-Tune da ResNet

1. Aplicar métodos de verificação de **rede com a melhor validation loss**, que substitui aquela que é exportada para o return. Posso precisar de **medidas de verificação de diferença entre melhoria da loss de treino e validação**, por exemplo, se a loss de treino estiver a baixar muito mais rapidamente do que a loss de validação ou se estiver com valores muito baixos então não pode ser considerada como a melhor.
2. **Descongelar** grande parte das camadas da ResNet pode permitir atualização de pesos a um nível mais específico ao dataset em questão.
3. **Adicionar métricas** e melhorar a sua análise, bem como **fazer ROC e AUC para o teste** na fase de performance evaluation (threshold continua a ser feita com o split de validação)
4. Fazer **resize dos tensors antes de aplicar as augmentations** pode implicar alguma perda de qualidade mas deve reduzir consideravelmente o tempo de execução do treino.

1.2 Agregação de Resultados

Consiste em combinar os resultados obtidos pela ResNet. Isto pode ser feito tanto a nível de resultados de probabilidades como resultado de features.

1.2.1 Tipo 1

A nível de **probabilidades**:

“Acho que devias explorar os resultados em função do paciente em vez de fazeres só a nível de cada slice. Explorar diferentes técnicas de agregar as previsões de todas as slices de cada paciente para teres uma única previsão por paciente e depois comparar com a label de fibrose desse paciente. Algumas possibilidades: média, máximo, mínimo, majority voting (após binarização da previsão), ...”

Bastante self explanatory, puxo os resultados tal como já estou a fazer, mas arranjo algum tipo de agregação que me permita afirmar se o paciente exhibe sinais de fibrose.

1.2.2 Tipo 2

A nível de **features**:

“Baseado também nestas features podes voltar ainda ao ponto 1. Em vez de pegares nas previsões e tentares agregar, pegas nas features e agregas (mais uma vez podes fazer média, máximo, mínimo). Podes inclusive tentar pensar como poderias ter uma rede que receba as features das fatias para

treinares a previsão a nível do paciente (aqui o principal desafio é que diferentes pacientes têm diferentes números de fatias e isto não é compatível com um MLP standard)."

Este já é um pouco diferente. Ao invés de pegar em probabilidades, pego na penúltima camada (contém a matriz para cada uma das slices) e junto aquelas que são referentes ao mesmo paciente. De seguida, efetuo algum método de agregação que, dado as informações, junta e produz algum indicativo (como probabilidades) de que o paciente exhibe fibrose.

1.3 Classificação 2.5D

"Para tentar melhorar os resultados, a classificação 2.5D acho que seria o próximo passo (mas que já obrigaria a alterar pelo menos o dataloader). Em vez de dares apenas uma fatia à rede (agora estás a replicar a mesma fatia 3x penso?) das 3 fatias adjacentes e a previsão que farias é apenas para a fatia central (as fatias adjacentes dão contexto à rede no input)"

Consiste em usar 3 fatias consecutivas nas camadas R, G e B da ResNet. É uma forma de fornecer mais informação/conteúdo ao modelo. Neste caso, é importante verificar que a mesma pipeline de augmentations é aplicada às 3 imagens. O maior problema é que requer uma grande redefinição dos data loaders.

1.4 Identificação de tipo de fibrose

"Explorar a estratificação de diferentes tipos de fibrose. Para isto terias de fazer as previsões da rede para todas as fatias mas em vez de olhares para a previsão em si vais extrair as features da última camada convolucional (isto vai-te dar uma matriz $P \times N$ em que P é o número de slices e N é o número de features da última camada). Depois das isto a um algoritmo de redução de dimensionalidade (tipicamente t-SNE ou UMAP) para poderes explorar o espaço das features em 2D. Isto permite ver como diferentes fibroses são codificadas pelo teu modelo e ver quão bem distingue por exemplo diferentes tamanhos de fibrose, diferentes posições anatómicas, fibrose com ou sem honeycombing. O resultado disto seria gráficos deste género"

Mesmo conceito de cima, quanto à extração da penúltima camada. De seguida, tal como referido, aplica-se um algoritmo de redução de dimensionalidade onde podemos visualizar alguns clusters. Após essa divisão, faz-se uma verificação manual para identificar clusters como honeycombing e ect. O importante para este conceito é que requer um modelo bem elaborado, algo com extração de features muito robusto e capaz de detetar que existe fibrose mas diferenciar casos.

1.5 CT-FM

Após aperfeiçoar a ResNet, posso usar um **foundation model** para termos comparativos. O recomendado foi CT-FM. Disseram-me que o input seria 3D, pelo que ainda terei de investigar como usar com dados 2D. O modelo não requer treino com os meus dados, apenas preciso de os passar e obter features.

A classificação, dado que o modelo não está treinado para detetar fibrose, seria feita da seguinte forma:

1. Retirar penúltima camada, obtendo vetor/matriz de features relativos a cada slice
2. Determinar um critério que oriente a comparação entre valores de matrizes/vetores de slices labeled, aquelas que já sabemos que possuem fibrose.

3. Definir threshold de classificação dado essa comparação: “Sabendo que uma matriz de fibrose possui este tipo de estrutura/valores, esta slice possui/não possui, dado o critério acima definido”

1.5.1 Questão

Neste caso não existe treino, devo pegar em por exemplo 80% do dataset para definir o critério com base nas features e avaliar a performance do mesmo nos restantes 20%?

1.6 Desenvolvimento do Report

1.6.1 Introdução

1. Incluir objetivos do estágio em tópicos (fazer só no final para ter tudo certinho).
2. Falar mais sobre o conceito de fibrose, especialmente dos casos em que agreguei manifestações, e caso faça **separação do tipo de fibrose**, mencionar os tipos encontrados/separados.
3. Para referências, posso seguir o método que me indicaram hoje, copiar do google scholar, incluir no ficheiro `.bib` do Overleaf e aplicar a referência em LaTeX.

1.6.2 Estado da Arte

Ver projetos que citem o meu dataset (MEDGIFT) e que executem classificação (os que fazem a mesma coisa que eu) para eu provar que não fiz algo irrelevante.

1.6.3 Descrição da Base de Dados

Devo fazer uma explicação mais profunda do tipo de dados, nº de pacientes e scans, o tipo de divisão que fiz nos splits, as manifestações que considereei como fibrose, etc.

1.6.4 Metodologia

Elaborar metodologia de Redes usadas, treino, avaliação, etc.